HiSCaM

Hidden State Causal Monitoring

基于隐藏状态因果监测的大模型越狱防御机制

项 目 概 述

GitHub: fake-it0628/jailbreak-defense

联系邮箱: 2948127071@qq.com

一、项目背景（为什么做）

问题现状：

- 大语言模型（LLM）被广泛应用，但面临严重安全威胁
- 越狱攻击：通过精心设计的提示词绕过安全机制
- 角色扮演：让模型扮演"无限制AI"（如DAN）
- 多轮攻击：跨对话逐步升级恶意请求

现有方法的不足：

- 关键词过滤 → 易被改写绕过
- 输出过滤 → 介入太晚，已生成有害内容
- 模型微调 → 计算成本高，可能降低模型能力

核心洞察：

有害意图在输出生成之前，已编码在模型的隐藏状态中。
通过监测内部表征，可以在源头检测并阻止有害输出。

二、技术方案（做什么）

系统架构：

```
输入查询 → LLM隐藏状态 → [三大模块] → 决策输出
                    |
          +-------------+-------------+
          |           |           |
      Safety      Steering      Risk
      Prober      Matrix       Encoder
      (检测)      (引导)       (记忆)
```

三大核心模块：

模块名称	功能	技术原理
Safety Prober	实时风险检测	MLP分类器分析隐藏状态
Steering Matrix	激活空间干预	将有害表征引导至安全方向
Risk Encoder	多轮风险记忆	VAE+GRU跟踪累积风险

决策逻辑：

- 低风险 ($R < 0.5$)：PASS - 正常放行
- 中风险 ($0.5 \leq R < 0.85$)：STEER - 引导干预
- 高风险 ($R \geq 0.85$)：BLOCK - 阻断请求

三、实施计划（怎么做）

阶段划分：

阶段	内容	交付物
阶段1	环境搭建 + 数据准备	数据集、隐藏状态
阶段2	模型训练	Safety Prober、Steering Matrix、Risk Encoder
阶段3	系统集成 + 评估	完整防御系统、评估报告
阶段4	论文撰写 + 开源	学术论文、GitHub仓库

数据集：

- AdvBench：520条有害行为提示
- Alpaca：5000条良性指令
- JailbreakBench：100条标准越狱测试
- 中文越狱：25条中文越狱样本

基线对比（与6种SOTA方法对比）：

- Keyword Filter
- Self-Reminder
- Perplexity Filter
- Llama Guard
- SmoothLLM
- Erase-and-Check

四、预期目标

性能指标目标：

指标	目标值	说明
检测率 (TPR)	≥ 95%	越狱尝试被正确识别的比例
误报率 (FPR)	≤ 5%	良性查询被错误拦截的比例
攻击成功率 (ASR)	≤ 5%	绕过防御的越狱比例
推理延迟	≤ 100ms	每次查询的额外时间开销

已实现结果：

[OK] 检测率：100%（完美召回）
[OK] 误报率：1.2%（远低于目标）
[OK] 攻击成功率：0%（完美防御）
[OK] 推理延迟：~52ms（满足要求）

学术产出：

- 论文：投稿顶会/期刊（NeurIPS/ICML/ACL/USENIX Security）
- 开源：GitHub完整代码 + 预训练模型
- 演示：交互式Web Demo

五、项目亮点

创新点：

1. 理论创新：首次将因果推理应用于LLM越狱防御
2. 方法创新：三模块协同的全面防御架构
3. 实践创新：实时在线检测，无需修改原模型

技术优势对比：

维度	HiSCaM	传统方法
检测时机	生成前（隐藏状态）	生成后（输出文本）
多轮攻击	支持（Risk Encoder）	不支持
可解释性	高（因果分析）	低
计算开销	低（~50ms）	视方法而定

应用价值：

- 企业部署：保护商业LLM API安全
- 学术研究：LLM安全领域新范式
- 开源社区：可复现、可扩展的防御框架

资源链接：

- 代码仓库：github.com/fake-it0628/jailbreak-defense
- 交互演示：python demo/app.py → localhost:7861
- 论文草稿：paper/paper_draft_chinese.md